



Life Lab: AI Agent 实验平台简介

赵俊宇 刘福康 岳雨婷

(中国科学技术大学 信息科学技术学院)

摘 要

在 Life Lab 中，拥有不同性格的 Agent 可以展现出不同的自主倾向与决策。用户用自然语言创建具有自主人格的 Agent，观察其在虚拟场景中的感知、决策与互动行为。系统基于 FastAPI + AutoGen + React + Phaser，在覆盖 Agent 全生命周期的八大基础模块之上，实现了三项核心能力：人格驱动的社会涌现（MBTI 人格直接决定 Agent 怎么移动、怎么社交、怎么产生情绪）、可信赖的多 Agent 协作（由 Agent 分工组队完成任务）、以及可量化的行为评测（多维度打分 + 信息论量化行为一致性 + 统计方法衡量跨任务稳定性）。最终使 Life Lab 从”有趣的 Agent 玩具”跃升为”可量化、可编排、可涌现的 Agent 社会系统”。

核心亮点

- **12 模块覆盖 Agent 全生命周期：**从人格铸造到行为评测到实验沉淀，七大阶段持续迭代
- **人格直接决定行为：**MBTI 影响 Agent 的对话风格、移动方式和情绪变化，不只是文字标签，而是可观测的行为差异
- **程序直接验证交付：**每一步是否真正执行由程序检查，不依赖 LLM 判断，最多 2 轮自动修订
- **用信息论量化行为：**统计 Agent 的工具使用习惯，计算行为一致性分数，配合逐维度诊断证据链，评测结果完全可解释
- **20+ 页面：**Agent 行为全链路实时可视化

关键词：AI Agent；社会模拟；人格建模；多智能体协作；行为指纹；管道编排

目录

1	引言	4
2	项目概述	4
2.1	定位与能力	4
3	从基础到涌现	5
4	核心能力一：人格驱动的社会涌现	6
5	核心能力二：可信赖的多 Agent 协作	7
6	核心能力三：可量化的行为评测	8
7	技术架构	9
8	核心创新点	10
9	差异化定位	10
10	应用场景	11
10.1	LLM 行为学对比研究	11
10.2	多 Agent 社会涌现观察	11
10.3	可信赖的多 Agent 工作流	11
10.4	AI 人格与交互设计教学	11
11	总结	12

1 引言

当前 AI Agent 系统有以下不足：**其一**，决策风格停留在 prompt 层面，用户缺乏对 Agent 决策风格的控制，导致人格并未真正影响决策与行动；**其二**，多 Agent 协作不可信赖，Agent 可能“幻觉交付”，声称完成任务却从未真正执行；**其三**，在非专业任务场景下，Agent 行为无法量化比较，“谁的 Agent 更好”只能靠主观判断，缺乏客观标准。

Life Lab 正是为应对这三大挑战而设计。其核心理念是：**你是导演，Agent 是演员**。你设定好角色和舞台，按下开始，看他们怎么演。我们关注的不仅是“Agent 能否完成任务”，更是“当 Agent 拥有了性格、情绪和同伴，会产生什么样的决策倾向”。

2 项目概述

2.1 定位与能力

Life Lab 构建了一个基于 FastAPI + AutoGen + React + Phaser 的 AI Agent 社会模拟平台。用户用自然语言描述一个角色，例如“来自小镇的计算机系新生，内向但野心大”，系统通过 LLM 自动生成该角色的完整人格，包括 MBTI、大五人格、决策风格、价值观、背景故事和层级化目标，并交由用户修改确认。

系统经历**七个阶段**持续迭代，从骨架搭建到图形化管线编辑器，逐步构建起完整的 Agent 社会实验能力：

阶段	名称	核心产出
阶段一	骨架搭建	M1-M8 八大模块 + 前端骨架
阶段二	联通补全	前后端联通 + 功能补全
阶段三	三大新模块	Agent Team + LLM Bench + 游戏化场景
阶段四	Agent 内核强化	工具真实化 + 上下文连续 + Scratchpad
阶段五	Worker 工作台	双轨工作区 + 管道编排
阶段六	三线并行	主动社交 + Worker 进阶
阶段七	Pipeline 深度化	图形化管线编辑器 + Loop/Branch 控制流

3 从基础到涌现

平台的基础层覆盖了 Agent 从”诞生”到”沉淀”的完整生命周期：自然语言铸造人格（M1）、单人与多人场景投放（M2/M3）、竞技对抗（M4）、叙事生成（M5）、上帝视角干预（M6/M7）、实验沉淀（M8）。



Figure 1: Agent 创建页面

模块	名称	核心能力
M1	铸造厂	自然语言 → 完整人格（MBTI + 五维度雷达 + 决策风格 + 背景故事 + 目标）
M2	单人剧场	单 Agent 场景投放，思维流实时展示
M3	群体沙盒	多 Agent 互动，关系动态演化，竞争博弈
M4	竞技场	1v1 辩论/面试/路演/盲测/大乱斗，LLM 裁判四维度评分
M5	叙事工厂	事件 → 9 种文体叙事（小说/日记/信/播客/平行叙事等）
M6	控制台	上帝视角仪表盘，事件热力图，决策模式识别
M7	干预台	运行时注入事件，向特定 Agent 发送指令
M8	档案馆	实验回放，模板沉淀，成就系统，报告导出

这些模块证明了 Life Lab 平台在 Agent 创建、观察、干预和沉淀方面提供的能力。

更重要的是，它们为下文的进阶能力提供了基础：M1 的人格建模驱动着游戏化场景中的移动与情绪，M3 的世界模拟经验沉淀为团队协作的设计范式，M6 的行为观测在评测基准中升级为可量化的分析体系。




Figure 2: 多 Agent 的社交模拟

真正让 Life Lab 在技术深度上脱颖而出的，是下面三项从基础中生长出来的核心能力。

4 核心能力一：人格驱动的社会涌现

问题：现有 Agent 系统的”人格”只是 prompt 中的几个形容词，影响 Agent”说什么”，但不影响”怎么做”。一个”内向”的 Agent 和一个”外向”的 Agent 在同一个虚拟场景中，移动方式、社交频率、情绪变化几乎完全相同。

方案：Life Lab 基于 Phaser 3 构建了 2D 瓦片地图场景并搭建了随机引擎，支持图书馆、宿舍、教室、艺术中心、实验室、樱花大道 6 种场景，将 MBTI 人格参数直接映射为游戏行为，由人格参数决定移动频率、探索范围和空闲概率，而非通过 prompt 间接影响：

- **人格驱动移动：**内向型 Agent 移动频率低、范围小、空闲率高；外向型则活跃得多。人格参数直接决定移动间隔、探索范围和空闲概率。
- **五重情绪引擎：**Agent 的情绪由五种因素共同驱动：对话内容、所处环境、附近 Agent 的情绪、随机事件、以及自然衰减。五种因素协同工作，让情绪变化自然且可观察。

- **社交涌现**：当两个 Agent 接近到一定距离，自动触发面对面多轮对话，内容由 LLM 根据双方人格实时生成。

成果：不同人格的 Agent 在相同场景下展现出**可辨识的行为差异**，内向者安静探索，外向者频繁社交，情绪在对话中起伏，关系在互动中演化，人格参数贯穿了 Agent 的全部行为维度。

5 核心能力二：可信赖的多 Agent 协作

问题：多 Agent 协作的最大风险是”**幻觉交付**”，Agent 声称完成了任务，但实际从未执行过关键操作。影响任务质量，动摇用户对 Agent 系统的信任。

方案：Life Lab 实现了从任务分解到交付验收的完整协作链路：

- **任务分解**：LLM 将任务拆解为子任务并分配给不同 Agent，LLM 不可用时降级为规则分配，并执行用户在设计阶段的修改。
- **共享工作区**：Agent 间通过文件系统协作，每步自动复制上游产出给下游，确保信息传递可追溯。
- **交付验收**：独立验收员检查 Agent 产出。**不完全依赖 LLM 判断**，程序直接算一遍算式对不对、查一遍工具调用记录是否真实存在。这些程序级检查的结果强制生效，即使 LLM 验收员判断出错也无法绕过，避免了”验收员和执行者犯同一类错误”的风险。首次不通过时自动退回修订，最多两轮。
- **角色演化与团队诊断**：执行过程中动态调整 Agent 角色，实时监控参与度和冲突。

成果：交付可信度从”靠 Agent 自觉”提升到”**程序直接验证**”。程序直接计算和工具记录核查确保即使 LLM 判断出错，错误仍然会被拦截。




Figure 3: 多 Agent 协作与任务产出

6 核心能力三：可量化的行为评测

问题：在非专业任务下，Agent 行为无法跨个体量化比较，”谁的 Agent 更聪明”只能靠主观判断，缺乏客观标准。

方案：Life Lab 基于 M1-8 的基础平台，构建了系统性的 Agent 行为评测体系：

- **六维雷达评测：**从人格一致性、决策质量、交互深度、鲁棒性、创造力、适应性六个维度打分。其中鲁棒性看的是 Agent 在多次任务中表现是否稳定，用统计中的变异系数 ($cv = \sigma/\mu$ ，即标准差除以均值) 衡量：每次得分差不多就满分，忽高忽低就低分。
- **行为一致性量化：**统计 Agent 使用了哪些工具、各用了多少次，用 Shannon 信息熵公式 $C = 1 - H(X)/H_{\max}$ (其中 $H(X) = -\sum p(x_i) \log_2 p(x_i)$) 计算一致性分数。 C 接近 1 说明行为很聚焦 (总是用同一种工具)，接近 0 说明很分散。这把”人格是否影响行为”变成了可以算出来的数学问题。
- **诊断证据链：**每个维度的分数都有具体证据支撑，比如”思考次数偏少 (5 次)，内部推理不充分”或”回复长度标准差: 42，能根据情境调整表达方式”。配合决策风格分类和劣化趋势检测，评测结果不是一个黑箱数字。

成果：不同 Agent 的行为模式可以在**同一尺度**上比较，评测结果完全**可解释**，可以看到”为什么这个维度得了这个分”的完整证据链。

7 技术架构

层	技术
后端框架	FastAPI (Python 3.12+)
Agent 编排	AutoGen 0.7+
数据库	SQLite + aiosqlite（异步 ORM）
前端框架	React 18 + Vite + TypeScript
样式	TailwindCSS
状态管理	React Query + Zustand
实时通信	SSE (Server-Sent Events)
游戏引擎	Phaser 3
LLM	OpenAI 兼容 API（DeepSeek / GLM / OpenAI）




Figure 4: Agent Team 任务编排

8 核心创新点

1. **人格直接决定行为**：MBTI 不仅影响 Agent 的对话风格，还直接决定移动频率、社交倾向和情绪变化，从”说什么”到”怎么走”再到”如何感受”，人格参数贯穿了 Agent 的全部行为维度，而非停留在 prompt 层面的伪人格。
2. **用信息熵量化行为一致性**：统计 Agent 的工具使用习惯，用 Shannon 信息熵公式 $C = 1 - H(X)/H_{\max}$ 计算一致性分数。 C 接近 1 说明行为聚焦，接近 0 说明行为分散，从而将”人格是否影响行为”从主观判断变为可计算的数学命题。
3. **用变异系数衡量跨任务稳定性**：定义鲁棒性 $R = \max(0, 100 - cv \times 100)$ ，其中 $cv = \sigma/\mu$ 是多次评测分数的变异系数。每次得分差不多就满分，忽高忽低就低分，实现用统计量替代主观判断。
4. **”快慢结合”双路径互保**：关键词匹配能在 1ms 内给出初步判断，但不够准确；LLM 深度评估需要数秒，但更可靠。两条路径独立运行、互相保险：快的保证实时性，慢的保证准确性。在交付验收中，程序直接算一遍算式对不对、查一遍工具调用记录是否真实存在，针对 llm 的运行随机性问题，我们选择用**确定性对抗随机性**：规则校验不会出错，LLM 判断可能出错，两条独立路径防止”验收员和执行者犯同一类错误”。这一模式贯穿关系评估、任务分解、交付验收等多个模块。




Figure 5: 管线编排与 workflow 管理

9 差异化定位

与现有 Agent 框架相比，Life Lab 的独特之处在于：

- AutoGen / CrewAI 侧重任务编排，虽有基础的角色设定能力，但缺乏系统性的人格建模和行为评测，在此开发框架下，Agent 更像是”工具”而非”角色”。
- LangGraph 侧重图编排，虽有静态可视化能力，但缺乏实时交互的游戏化场景和社会涌现，用户无法显式观察 Agent 的动态”社会行为”。
- AgentBench 侧重基准测试，有评测能力但只给分数不给原因，缺乏可解释的诊断证据链。

Life Lab 的独特定位是：**不仅是 Agent 编排工具，更是 Agent 实验平台**，它同时提供人格建模、行为评测和游戏化场景，让研究者能够创建、观察、量化和干预 AI Agent 的社会行为。

10 应用场景

Life Lab 的独特能力——人格驱动行为、可信赖协作、可解释评测——打开了以下应用空间：

10.1 LLM 行为学对比研究

不同大语言模型（DeepSeek、GLM、GPT 等）在相同人格设定下，行为模式是否存在显著差异？传统基准测试（如 MMLU、HumanEval）只能衡量”答题能力”，无法揭示”行为风格”。Life Lab 的行为一致性量化和六维雷达提供了一个全新的比较维度：将同一角色人格投放到相同场景，通过信息熵公式计算行为一致性分数，量化比较不同模型在决策风格、情绪稳定性、社交倾向等方面的差异。

10.2 多 Agent 社会涌现观察

当多个具有不同性格的 Agent 被放入同一场景，会涌现怎样的社会结构？是否会形成小团体？冲突如何产生和化解？意见领袖如何自然出现？Life Lab 的游戏化场景和五重情绪引擎使这些社会心理学经典问题在 AI Agent 身上得到可重复、可量化的研究。研究者可以通过干预台注入事件、通过控制台观察关系网络演化、通过档案馆回放完整实验过程。

10.3 可信赖的多 Agent 工作流

在多 Agent 协作中，“幻觉交付”是落地的最大障碍，Agent 声称完成了任务，但关键步骤实际未执行。Life Lab 的 Worker 管道引擎通过程序直接验证和自动修订机制，将交付可信度从“靠 Agent 自觉”提升到“程序化可验证”。这使得 Life Lab 的协作引擎不仅适用于实验场景，也可用于需要可审计、可追溯的自动化工作流。

10.4 AI 人格与交互设计教学

Life Lab 提供了一个直观的、可视化的 AI 人格实验环境：用户用自然语言创建角色，实时观察 Agent 在场景中的行为，通过评测基准量化分析结果。从“铸造人格 → 投放场景 → 观察行为 → 量化评测 → 调整优化”的完整闭环，使抽象的 AI 概念（人格建模、行为涌现、多智能体协作）变得可感知、可实验。

11 总结

大多数 Agent 项目止步于“让 Agent 完成任务”。Life Lab 关注的是一个旁路但重要的问题：当 Agent 拥有了性格、情绪和同伴，它们会怎样？

七个阶段、12 个模块的持续迭代，Life Lab 构建了三项其他框架不具备的能力：人格直接决定行为、程序直接验证交付、基于信息论和统计学的量化。这三项能力使 Life Lab 从“有趣的 Agent 玩具”跃升为“可量化、可编排、可涌现的 Agent 社会实验平台”。

Life Lab 不只是一个竞赛作品，它是一个研究者和学生可以真正用来探索 AI 社会性行为的工具。人格可以被铸造，行为可以被观测，涌现可以被量化，协作可以被信赖。这是 Life Lab 与其他 Agent 项目最本质的区别。