



Life Lab: AI Agent 实验平台简介

赵俊宇 刘福康 岳雨婷

(中国科学技术大学 信息科学技术学院)

摘 要

在 Life Lab 中，拥有不同性格的 Agent 可以展现出不同的自主倾向与决策。用户用自然语言创建具有自主人格的 Agent，观察其在虚拟场景中的感知、决策与互动行为。系统基于 FastAPI + AutoGen + React + Phaser，在覆盖 Agent 全生命周期的八大基础模块之上，实现了三项核心能力：**人格驱动的社会涌现**（MBTI 人格直接决定 Agent 怎么移动、怎么社交、怎么产生情绪）、**可信赖的多 Agent 协作**（由 Agent 分工组队完成任务）、以及**可量化的行为评测**（多维度打分 + 信息论量化行为一致性 + 统计方法衡量跨任务稳定性）。最终使 Life Lab 从“有趣的 Agent 玩具”跃升为“可量化、可编排、可涌现的 Agent 社会系统”。

核心亮点

- **12 模块覆盖 Agent 全生命周期：**从人格铸造到行为评测到实验沉淀，七大阶段持续迭代
- **人格直接决定行为：**MBTI 影响 Agent 的对话风格、移动方式和情绪变化，不只是文字标签，而是可观测的行为差异
- **程序直接验证交付：**每一步是否真正执行由程序检查，不依赖 LLM 判断，最多 2 轮自动修订
- **用信息论量化行为：**统计 Agent 的工具使用习惯，计算行为一致性分数，配合逐维度诊断证据链，评测结果完全可解释
- **20+ 页面：**Agent 行为全链路实时可视化

关键词：AI Agent；社会模拟；人格建模；多智能体协作；行为指纹；管道编排

目录

1 引言

当前 AI Agent 系统有以下不足：**其一**，决策风格停留在 prompt 层面，用户缺乏对 Agent 决策风格的控制，导致人格并未真正影响决策与行动；**其二**，多 Agent 协作不可信赖，Agent 可能“幻觉交付”，声称完成任务却从未真正执行；**其三**，在非专业任务场景下，Agent 行为无法量化比较，“谁的 Agent 更好”只能靠主观判断，缺乏客观标准。

Life Lab 正是为应对这三大挑战而设计。其核心理念是：**你是导演，Agent 是演员**。你设定好角色和舞台，按下开始，看他们怎么演。我们关注的不仅是“Agent 能否完成任务”，更是“当 Agent 拥有了性格、情绪和同伴，会产生什么样的决策倾向”。

2 项目概述

2.1 定位与能力

Life Lab 构建了一个基于 **FastAPI + AutoGen + React + Phaser** 的 AI Agent 社会模拟平台。用户用自然语言描述一个角色，例如“来自小镇的计算机系新生，内向但野心大”，系统通过 LLM 自动生成该角色的完整人格，包括MBTI、大五人格、决策风格、价值观、背景故事和层级化目标，并交由用户修改确认。

系统经历**七个阶段**持续迭代，从骨架搭建到图形化管线编辑器，逐步构建起完整的 Agent 社会实验能力：

阶段	名称	核心产出
阶段一	骨架搭建	M1-M8 八大模块 + 前端骨架
阶段二	联通补全	前后端联通 + 功能补全
阶段三	三大新模块	Agent Team + LLM Bench + 游戏化场景
阶段四	Agent 内核强化	工具真实化 + 上下文连续 + Scratchpad
阶段五	Worker 工作台	双轨工作区 + 管道编排
阶段六	三线并行	主动社交 + Worker 进阶
阶段七	Pipeline 深度化	图形化管线编辑器 + Loop/Branch 控制流

3 从基础到涌现

平台的基础层覆盖了 Agent 从”诞生”到”沉淀”的完整生命周期：自然语言铸造人格（M1）、单人与多人场景投放（M2/M3）、竞技对抗（M4）、叙事生成（M5）、上帝视角干预（M6/M7）、实验沉淀（M8）。



Figure 1: Agent 创建页面

模块	名称	核心能力
M1	铸造厂	自然语言 → 完整人格（MBTI + 五维度雷达 + 决策风格 + 背景故事 + 目标）
M2	单人剧场	单 Agent 场景投放，思维流实时展示
M3	群体沙盒	多 Agent 互动，关系动态演化，竞争博弈
M4	竞技场	1v1 辩论/面试/路演/盲测/大乱斗，LLM 裁判 四维度评分
M5	叙事工厂	事件 → 9 种文体叙事（小说/日记/信/播客/平行叙事等）
M6	控制台	上帝视角仪表盘，事件热力图，决策模式识别
M7	干预台	运行时注入事件，向特定 Agent 发送指令
M8	档案馆	实验回放，模板沉淀，成就系统，报告导出

这些模块证明了 Life Lab 平台在 Agent 创建、观察、干预和沉淀方面提供的能力。更重要的是，它们为下文的进阶能力提供了基础：M1 的人格建模驱动着游戏化场景中的移动与情绪，M3 的世界模拟经验沉淀为团队协作的设计范式，M6 的行为观测在评测基准中升级为可量化的分析体系。




Figure 2: 多Agent的社交模拟

真正让 Life Lab 在技术深度上脱颖而出的，是下面三项从基础中生长出来的核心能力。

4 核心能力一：人格驱动的社会涌现

问题：现有 Agent 系统的”人格”只是 prompt 中的几个形容词，影响 Agent”说什么”，但不影响”怎么做”。一个”内向”的 Agent 和一个”外向”的 Agent 在同一个虚拟场景中，移动方式、社交频率、情绪变化几乎完全相同。

方案：Life Lab 基于 Phaser 3 构建了 2D 瓦片地图场景并搭建了随机引擎，支持图书馆、宿舍、教室、艺术中心、实验室、樱花大道 6 种场景，将 MBTI 人格参数直接映射为游戏行为，由人格参数决定移动频率、探索范围和空闲概率，而非通过 prompt 间接影响：

- **人格驱动移动：**内向型 Agent 移动频率低、范围小、空闲率高；外向型则活跃得多。人格参数直接决定移动间隔、探索范围和空闲概率。
- **五重情绪引擎：**Agent 的情绪由五种因素共同驱动：对话内容、所处环境、附近

Agent 的情绪、随机事件、以及自然衰减。五种因素协同工作，让情绪变化自然且可观察。

- **社交涌现：**当两个 Agent 接近到一定距离，自动触发面对面多轮对话，内容由 LLM 根据双方人格实时生成。

成果：不同人格的 Agent 在相同场景下展现出可辨识的行为差异，内向者安静探索，外向者频繁社交，情绪在对话中起伏，关系在互动中演化，人格参数贯穿了 Agent 的全部行为维度。

5 核心能力二：可信赖的多 Agent 协作

问题：多 Agent 协作的最大风险是“幻觉交付”，Agent 声称完成了任务，但实际从未执行过关键操作。影响任务质量，动摇用户对 Agent 系统的信任。

方案：Life Lab 实现了从任务分解到交付验收的完整协作链路：

- **任务分解：**LLM 将任务拆解为子任务并分配给不同 Agent，LLM 不可用时降级为规则分配，并执行用户在设计阶段的修改。
- **共享工作区：**Agent 间通过文件系统协作，每步自动复制上游产出给下游，确保信息传递可追溯。
- **交付验收：**独立验收员检查 Agent 产出。不完全依赖 LLM 判断，程序直接算一遍算式对不对、查一遍工具调用记录是否真实存在。这些程序级检查的结果强制生效，即使 LLM 验收员判断出错也无法绕过，避免了“验收员和执行者犯同一类错误”的风险。首次不通过时自动退回修订，最多两轮。
- **角色演化与团队诊断：**执行过程中动态调整 Agent 角色，实时监控参与度和冲突。

成果：交付可信度从“靠 Agent 自觉”提升到“程序直接验证”。程序直接计算和工具记录核查确保即使 LLM 判断出错，错误仍然会被拦截。




Figure 3: 多 Agent 协作与任务产出

6 核心能力三：可量化的行为评测

问题：在非专业任务下，Agent 行为无法跨个体量化比较，“谁的 Agent 更聪明”只能靠主观判断，缺乏客观标准。

方案：Life Lab 基于 M1-8 的基础平台，构建了系统性的 Agent 行为评测体系：

- 六维雷达评测：**从人格一致性、决策质量、交互深度、鲁棒性、创造力、适应性六个维度打分。其中鲁棒性看的是 Agent 在多次任务中表现是否稳定，用统计中的变异系数 ($cv = \sigma/\mu$ ，即标准差除以均值) 衡量：每次得分差不多就满分，忽高忽低就低分。
- 行为一致性量化：**统计 Agent 使用了哪些工具、各用了多少次，用 Shannon 信息熵公式 $C = 1 - H(X)/H_{\max}$ (其中 $H(X) = -\sum p(x_i) \log_2 p(x_i)$) 计算一致性分数。 C 接近 1 说明行为很聚焦 (总是用同一种工具)，接近 0 说明很分散。这把“人格是否影响行为”变成了可以算出来的数学问题。
- 诊断证据链：**每个维度的分数都有具体证据支撑，比如“思考次数偏少(5次)，内部推理不充分”或“回复长度标准差: 42，能根据情境调整表达方式”。配合决策风格分类和劣化趋势检测，评测结果不是一个黑箱数字。

成果：不同 Agent 的行为模式可以在**同一尺度**上比较，评测结果完全**可解释**，可以看到“为什么这个维度得了这个分”的完整证据链。

7 平台运行评测数据

平台在实际运行中积累了完整的评测数据，所有数据存储于 SQLite 数据库，以下数据均从数据库中直接提取。

7.1 评测数据总览

数据类型	记录数
Bench 完整评测运行	4 次（全部完成，27/27 任务）
Bench 子结果	94 条
Arena 竞技对抗	1 场（6 人大乱斗）
Team 团队协作	5 个团队，14 个计划
Agent 实例	25 个
World 世界实例	48 个
Simulation 模拟运行	47 次

4 次 Bench 评测均使用 deepseek-v4-flash 模型，采用标准评测套件（3 Agent × 3 场景 × 3 重复 = 27 条评测记录/次）。

7.2 六维雷达评测结果

维度	运行 1	运行 2	运行 3	运行 4	平均
人格一致性	32.6	31.2	35.1	32.6	32.9
决策质量	32.8	33.8	37.4	35.6	34.9
交互深度	32.6	34.3	35.7	33.7	34.1
鲁棒性	92.6	92.4	92.0	94.1	92.8
创造力	57.8	57.2	54.1	57.4	56.6
适应性	89.3	87.0	86.6	92.3	88.8

鲁棒性使用变异系数计算： $cv = \sigma/\mu$ ， $R = \max(0, 100 - cv \times 100)$ 。

7.3 分 Agent 与分场景聚合

Agent	场景	人格	决策	交互	鲁棒	创造	适应
学霸小明	期末周	45.8	30.0	28.4	80.0	66.0	91.7
学霸小明	新生报到	33.1	30.0	26.8	80.0	58.8	97.7
社交小红	毕业选择	38.2	33.1	30.2	80.0	57.5	81.1
领导者小刚	毕业选择	30.0	55.0	66.4	80.0	49.3	100.0
领导者小刚	新生报到	30.0	33.6	40.1	80.0	53.1	78.4

7.4 评测结果分析

- **鲁棒性最强**（平均 92.8 分）：模型在跨场景、跨重复运行中表现高度稳定。
- **人格一致性最弱**（平均 32.9 分）：Agent 行为未能严格遵循 MBTI 设定，是后续优化的核心方向。
- **人格与场景耦合**：学霸小明在期末周人格一致性最高（45.8），领导者小刚在毕业选择场景交互深度最高（66.4）。
- **适应性波动显著**（78.4–97.7）：不同人格对环境变化的响应模式存在显著差异。

8 技术架构

层	技术
后端框架	FastAPI (Python 3.12+)
Agent 编排	AutoGen 0.7+
数据库	SQLite + aiosqlite (异步 ORM)
前端框架	React 18 + Vite + TypeScript
样式	TailwindCSS
状态管理	React Query + Zustand
实时通信	SSE (Server-Sent Events)
游戏引擎	Phaser 3
LLM	OpenAI 兼容 API (DeepSeek / GLM / OpenAI)




Figure 4: Agent Team 任务编排

9 核心创新点

- 1. 人格直接决定行为: MBTI 不仅影响 Agent 的对话风格, 还直接决定移动频率、社交倾向和情绪变化, 从”说什么”到”怎么走”再到”如何感受”, 人格参数贯穿了 Agent 的全部行为维度, 而非停留在 prompt 层面的伪人格。

2. 用信息熵量化行为一致性：统计 Agent 的工具使用习惯，用 Shannon 信息熵公式 $C = 1 - H(X)/H_{\max}$ 计算一致性分数。 C 接近 1 说明行为聚焦，接近 0 说明行为分散，从而将“人格是否影响行为”从主观判断变为可计算的数学命题。
3. 用变异系数衡量跨任务稳定性：定义鲁棒性 $R = \max(0, 100 - cv \times 100)$ ，其中 $cv = \sigma/\mu$ 是多次评测分数的变异系数。每次得分差不多就满分，忽高忽低就低分，实现用统计量替代主观判断。
4. “快慢结合”双路径互保：关键词匹配能在 1ms 内给出初步判断，但不够准确；LLM 深度评估需要数秒，但更可靠。两条路径独立运行、互相保险：快的保证实时性，慢的保证准确性。在交付验收中，程序直接算一遍算式对不对、查一遍工具调用记录是否真实存在，针对llm的运行随机性问题，我们选择用确定性对抗随机性：规则校验不会出错，LLM 判断可能出错，两条独立路径防止“验收员和执行者犯同一类错误”。这一模式贯穿关系评估、任务分解、交付验收等多个模块。




Figure 5: 管线编排与 workflow 管理

10 差异化定位

与现有 Agent 框架相比，Life Lab 的独特之处在于：

- **AutoGen / CrewAI** 侧重任务编排，虽有基础的角色设定能力，但缺乏系统性的人格建模和行为评测，在此开发框架下，Agent 更像是”工具”而非”角色”。
- **LangGraph** 侧重图编排，虽有静态可视化能力，但缺乏实时交互的游戏化场景和社会涌现，用户无法显式观察 Agent 的动态”社会行为”。

- **AgentBench** 侧重基准测试，有评测能力但只给分数不给原因，缺乏可解释的诊断证据链。

Life Lab 的独特定位是：不仅是 **Agent** 编排工具，更是 **Agent** 实验平台，它同时提供人格建模、行为评测和游戏化场景，让研究者能够创建、观察、量化和干预 AI Agent 的社会行为。

11 应用场景

Life Lab 的独特能力——人格驱动行为、可信赖协作、可解释评测——打开了以下应用空间：

11.1 LLM 行为学对比研究

不同大语言模型（DeepSeek、GLM、GPT 等）在相同人格设定下，行为模式是否存在显著差异？传统基准测试（如 MMLU、HumanEval）只能衡量“答题能力”，无法揭示“行为风格”。Life Lab 的行为一致性量化和六维雷达提供了一个全新的比较维度：将同一角色人格投放到相同场景，通过信息熵公式计算行为一致性分数，量化比较不同模型在决策风格、情绪稳定性、社交倾向等方面的差异。

11.2 多 Agent 社会涌现观察

当多个具有不同性格的 Agent 被放入同一场景，会涌现怎样的社会结构？是否会形成小团体？冲突如何产生和化解？意见领袖如何自然出现？Life Lab 的游戏化场景和五重情绪引擎使这些社会心理学经典问题在 AI Agent 身上得到可重复、可量化的研究。研究者可以通过干预台注入事件、通过控制台观察关系网络演化、通过档案馆回放完整实验过程。

11.3 可信赖的多 Agent workflow

在多 Agent 协作中，“幻觉交付”是落地的最大障碍，Agent 声称完成了任务，但关键步骤实际未执行。Life Lab 的 Worker 管道引擎通过程序直接验证和自动修订机制，将交付可信度从“靠 Agent 自觉”提升到“程序化可验证”。这使得 Life Lab 的协作引擎不仅适用于实验场景，也可用于需要可审计、可追溯的自动化 workflow。

11.4 AI人格与交互设计教学

Life Lab 提供了一个直观的、可视化的 AI 人格实验环境：用户用自然语言创建角色，实时观察 Agent 在场景中的行为，通过评测基准量化分析结果。从”铸造人格 → 投放场景 → 观察行为 → 量化评测 → 调整优化”的完整闭环，使抽象的 AI 概念（人格建模、行为涌现、多智能体协作）变得可感知、可实验。

12 总结

大多数 Agent 项目止步于”让 Agent 完成任务”。Life Lab 关注的是一个旁路但重要的问题：当 Agent 拥有了性格、情绪和同伴，它们会怎样？

七个阶段、12 个模块的持续迭代，Life Lab 构建了三项其他框架不具备的能力：人格直接决定行为、程序直接验证交付、基于信息论和统计学的量化。这三项能力使 Life Lab 从”有趣的 Agent 玩具”跃升为”可量化、可编排、可涌现的 Agent 社会实验平台”。

更重要的是，平台在实际运行中积累了 **94 条评测子结果**，鲁棒性维度平均得分 **92.8 分**（跨场景高度稳定），为模型行为分析提供了可量化的实验基础。这不是一个仅能演示的玩具，而是一个研究者可以真正用来探索 AI 社会性行为的工具。

Life Lab 不只是一个竞赛作品，它是一个研究者和学生可以真正用来探索 AI 社会性行为的工具。人格可以被铸造，行为可以被观测，涌现可以被量化，协作可以被信赖。这是 Life Lab 与其他 Agent 项目最本质的区别。