



Life Lab: AI Agent 实验平台简介

赵俊宇 刘福康 岳雨婷

(中国科学技术大学 信息科学技术学院)

摘 要

在 Life Lab 中，拥有不同性格的 Agent 可以展现出差异化的自主倾向与决策。用户用自然语言创建具有自主人格的 Agent，观察其在虚拟校园场景中的感知、决策与互动行为。系统基于 FastAPI + AutoGen + React + Phaser，在覆盖 Agent 全生命周期的八大基础模块之上，实现了三项核心能力：人格驱动的社会涌现（MBTI 人格直接决定 Agent 怎么移动、怎么社交、怎么产生情绪）、可信赖的多 Agent 协作（DAG 管道编排 + 程序级交付验证，Agent 分工组队完成复杂任务）、以及可量化的行为评测（六维雷达 + 信息论量化行为一致性 + 统计方法衡量跨任务稳定性）。最终使 Life Lab 从“有趣的 Agent 玩具”跃升为“可量化、可编排、可涌现的 Agent 社会系统”。

核心亮点

- 12 模块覆盖 Agent 全生命周期：从人格铸造到行为评测到实验沉淀，七大阶段持续迭代
- 人格直接决定行为：MBTI 影响 Agent 的对话风格、移动方式和情绪变化，不只是文字标签，而是可观测的行为差异
- DAG 管道编排 + 程序直接验证交付：支持 Loop/Branch 控制流，每一步是否真正执行由程序检查，不依赖 LLM 判断，最多 2 轮自动修订
- 用信息论量化行为：统计 Agent 的工具使用习惯，计算行为一致性分数，配合逐维度诊断证据链，评测结果完全可解释
- 多模型集成：支持 DeepSeek / GLM / OpenAI，统一 OpenAI 兼容 API，内置超时重试与降级兜底
- 20+ 页面：Agent 行为全链路实时可视化 + Phaser 3 游戏化场景 + 图形化管线编辑器

关键词：AI Agent；社会模拟；人格建模；多智能体协作；行为指纹；管道编排

目录

1	引言	4
2	平台概览与技术架构	4
3	创新一：人格驱动的社会涌现	7
4	创新二：多 Agent 协作与 Workflow 设计	8
5	创新三：可量化的行为评测	11
6	大模型应用深度与调试优化	12
6.1	模型接入与调用方式	12
6.2	容错与调试策略	12
7	评测数据与实证分析	13
7.1	评测数据总览	14
7.2	六维雷达评测结果	14
7.3	分 Agent 与分场景聚合	15
7.4	评测结果分析	15
8	应用场景与推广价值	15
8.1	个性化成长指导	15
8.2	AI 同伴社交模拟	16
8.3	可信赖的多 Agent 协作	16
8.4	AI 人格实验与教学	16
9	总结	16

1 引言

当前 AI Agent 系统有以下不足：**其一**，决策风格停留在 prompt 层面，用户缺乏对 Agent 决策风格的控制，导致人格并未真正影响决策与行动；**其二**，多 Agent 协作不可信赖，Agent 可能“幻觉交付”，声称完成任务却从未真正执行；**其三**，在非专业任务场景下，Agent 行为无法量化比较，“谁的 Agent 更好”只能靠主观判断，缺乏客观标准。

Life Lab 正是为应对这三大挑战而设计。其核心理念是：**你是导演，Agent 是演员。你设定好角色和舞台，按下开始，看他们怎么演。**我们关注的不仅是“Agent 能否完成任务”，更是“当 Agent 拥有了性格、情绪和同伴，会产生什么样的决策倾向”。平台基于**真实场景构建**（图书馆、宿舍、教室、艺术中心、实验室、樱花大道 6 种场景），贴近学生日常学习与生活，使 Agent 行为更具真实感和说服力。与 AutoGen / CrewAI 侧重任务编排、LangGraph 侧重图编排、AgentBench 侧重黑箱评分不同，Life Lab 的独特定位是 Agent **社会实验平台**，同时提供人格建模、行为评测和游戏化场景。Life Lab 已积累 25 个 Agent、48 个世界实例、47 次模拟运行，形成了完整的功能闭环。

2 平台概览与技术架构

Life Lab 构建了一个基于 FastAPI + AutoGen + React + Phaser 的 AI Agent 社会模拟平台。用户用自然语言描述一个角色，例如“来自小镇的计算机系新生，内向但野心大”，系统通过 LLM 自动生成该角色的完整人格，包括 MBTI、大五人格、决策风格、价值观、背景故事和层级化目标，并交由用户修改确认。

系统经历**七个阶段**持续迭代，从骨架搭建到图形化管线编辑器，逐步构建起完整的 Agent 社会实验能力：

阶段	名称	核心产出
阶段一	骨架搭建	M1-M8 八大模块 + 前端骨架
阶段二	联通补全	前后端联通 + 功能补全
阶段三	三大新模块	Agent Team + LLM Bench + 游戏化场景
阶段四	Agent 内核强化	工具真实化 + 上下文连续 + Scratchpad
阶段五	Worker 工作台	双轨工作区 + 管道编排
阶段六	三线并行	主动社交 + Worker 进阶
阶段七	Pipeline 深度化	图形化管线编辑器 + Loop/Branch 控制流

平台共实现 12 个功能模块，覆盖 Agent 从“诞生”到“沉淀”的完整生命周期：自然语言铸造人格（M1）、单人与多人场景投放（M2/M3）、竞技对抗（M4）、叙事生成（M5）、上帝视角干预（M6/M7）、实验沉淀（M8）、团队协作（M9）、行为评测（M10）、游戏化场景（M11）、管道编排（M12）。12 个模块不是功能的简单堆叠，而是层层递进：M1 的人格建模驱动 M11 游戏化场景中的移动与情绪，M3 的世界模拟经验沉淀为 M9 团队协作的设计范式，M6 的行为观测在 M10 评测基准中升级为可量化的分析体系。


Figure 1: Agent 创建页面: 自然语言描述 $\rightarrow$ 完整人格

Figure 2: 多 Agent 社交模拟：人格驱动的自主互动

系统模块按能力由浅到深分为四层, 如图 3 所示:




Figure 3: Life Lab 系统技术架构图：表现层 → 接口层 → 引擎层 → 数据层。LLM 服务通过 OpenAI 兼容 API 接入。

平台经过七个阶段的持续迭代，从骨架搭建到融合闭环，逐步构建起完整的 Agent 社会实验能力，如图 4 所示：




Figure 4: Life Lab 七阶段连续演进：从 Agent 世界（STATE 1）到融合闭环（STATE 7），涵盖完整前后端、真实执行、LLM Bench、Pipeline 工作流等核心能力。

层	技术
后端框架	FastAPI (Python 3.12+)
Agent 编排	AutoGen 0.7+
数据库	SQLite + aiosqlite (异步 ORM)
前端框架	React 18 + Vite + TypeScript
样式	TailwindCSS
状态管理	React Query + Zustand
实时通信	SSE (Server-Sent Events)
游戏引擎	Phaser 3
LLM	OpenAI 兼容 API (DeepSeek / GLM / OpenAI)

3 创新一：人格驱动的社会涌现

问题：现有 Agent 系统的”人格”只是 prompt 中的几个形容词，影响 Agent”说什么”，但不影响”怎么做”。一个”内向”的 Agent 和一个”外向”的 Agent 在同一个虚拟场景中，移动方式、社交频率、情绪变化几乎完全相同。

方案：Life Lab 基于 Phaser 3 构建了 2D 瓦片地图场景并搭建了随机引擎，支持图书馆、宿舍、教室、艺术中心、实验室、樱花大道 6 种场景，将 MBTI 人格参数直接映射为游戏行为，由人格参数直接决定移动频率、探索范围和空闲概率，而非通过 prompt 间接影响：

- **人格驱动移动：**内向型 Agent 移动频率低、范围小、空闲率高；外向型则活跃得多。具体地，内向思考型 (I_T_) 移动间隔 9–16s、最大探索范围 2 格、空闲概率 45%，外向情感型 (E_F_) 移动间隔 3.5–8s、范围 3 格、空闲概率仅 10%，行为差异直接可观测。
- **五重情绪引擎：**Agent 的情绪由五种因素共同驱动：对话内容（18 条正则规则匹配 8 种情绪）、环境氛围（6 种场景各有情绪偏向）、附近 Agent 的情绪共鸣（3 格内同频放大/异频中和）、随机事件（25+ 事件池，每 30–70s 触发）、以及自然衰减（每 30s 向中性回归）。三种独立定时器协同工作，使情绪变化具有真实的时间节律。
- **社交涌现：**当两个 Agent 接近到一定距离，自动触发面对面多轮对话，内容由 LLM

根据双方人格实时生成。移动目标选择采用 25% 物品寻求 + 40% 社交接近 + 35% 随机漫游的混合策略，使 Agent 的行为既有目的性又有随机性。

以图书馆场景为例，人格差异直接可观测：INTJ-T 的”学霸小明”走进图书馆后，径直走向角落的电脑区（最大探索范围 2 格），在书架间停留较久（移动间隔 9–16s），45% 的时间站在原地”思考”。与此同时，ENFP-A 的”社交小红”进入同一场景，快速穿梭于各个区域（间隔 3.5–8s，范围 3 格），主动靠近其他 Agent（社交接近权重 25%），空闲概率仅 10%，她几乎从不停下来。当两人偶遇时，LLM 根据双方人格实时生成对话：小红热情地分享近况，小明简短回应后继续走向电脑区。情绪引擎同步工作：小红因”图书馆的安静氛围”获得中性情绪微调，小明因”实验数据对上了”的随机事件触发兴奋情绪。

成果：不同人格的 Agent 在相同场景下展现出**可辨识的行为差异**，内向者安静探索，外向者频繁社交，情绪在对话中起伏，关系在互动中演化，人格参数贯穿了 Agent 的全部行为维度。评测数据显示人格与场景存在显著耦合效应：学霸小明在期末周（高压学术场景）人格一致性最高（45.8），领导者小刚在毕业选择场景交互深度最高（66.4），适应性维度在不同人格间波动显著（78.4–97.7）。

4 创新二：多 Agent 协作与 Workflow 设计

问题：多 Agent 协作的最大风险是”幻觉交付”，Agent 声称完成了任务，但实际从未执行过关键操作。影响任务质量，动摇用户对 Agent 系统的信任。

方案：Life Lab 实现了从任务分解到交付验收的完整协作链路，支持多 Agent 分工组队完成复杂任务：

- **任务分解：**LLM 将任务拆解为子任务并分配给不同 Agent，LLM 不可用时降级为规则分配（8 种预设角色模板），并执行用户在设计阶段的修改。
- **DAG 管道编排：**支持 DAG 拓扑排序 + 层级并行执行（同层最多 3 路并行），并扩展支持 Loop（回边循环）和 Branch（条件跳转）两种控制流，条件值从节点真实产出文件中读取，支持正则/数值/关键词三种匹配模式。
- **共享工作区：**Agent 间通过文件系统协作，每步自动复制上游产出给下游，确保信息传递可追溯。

- **交付验收：**独立验收员检查 Agent 产出。**不完全依赖 LLM 判断**，程序直接算一遍算式对不对、查一遍工具调用记录是否真实存在。这些程序级检查的结果强制生效，即使 LLM 验收员判断出错也无法绕过，避免了“验收员和执行者犯同一类错误”的风险。首次不通过时自动退回修订，最多两轮。
- **Worker 状态机：**每个 Worker 通过 6 状态显式状态机管理生命周期，反思阶段可回到决策或规划，形成“执行 → 验收 → 修订”的闭环迭代。错误处理采用三级策略：RETRYABLE（自动重试）/SKIPPABLE（Agent 自主决策）/FATAL（立即终止）。

以“策划校园科技节”为例，完整协作链路如下：用户提交任务后，LLM 将任务分解为 3 个子任务——“调研往届案例”“设计活动方案”“撰写预算报告”，分别分配给 3 个 Agent。DAG 引擎分析依赖关系：调研无前置依赖可立即执行，方案设计依赖调研结果，预算报告依赖方案设计。执行过程中，Agent A 通过 `web_search` 搜索往届案例并写入 `workspace/step_1.md`；验收员检查时发现“调研报告缺少数据来源”，程序级台账核验确认 `web_search` 未被调用，判定不通过；Agent A 收到反馈后自动修订，补充搜索并重新提交；验收通过后，产出自动复制到 Agent B 的工作区，Agent B 基于真实文件开始方案设计。整个过程在管线编辑器中可视化呈现，每个节点的状态（执行中/验收中/已完成/修订中）实时更新。

成果：交付可信度从“靠 Agent 自觉”提升到“程序直接验证”。程序直接计算和工具记录核查确保即使 LLM 判断出错，错误仍然会被拦截。5 个团队共执行 14 个计划，验证了任务分解、执行幂等性和交付硬校验等核心特性。




Figure 5: 多 Agent 协作与任务产出




Figure 6: Worker 工作台：工具调用与文件产出



Figure 7: 六维行为评测雷达图 + 评分诊断报告



Figure 8: Phaser 3 游戏化场景：图书馆中的 Agent 自主互动

5 创新三：可量化的行为评测

问题：在非专业任务下，Agent 行为无法跨个体量化比较，”谁的 Agent 更聪明”只能靠主观判断，缺乏客观标准。

方案：Life Lab 基于 M1-8 的基础平台，构建了系统性的 Agent 行为评测体系：

- **六维雷达评测：**从人格一致性、决策质量、交互深度、鲁棒性、创造力、适应性六个维度打分。其中鲁棒性看的是 Agent 在多次任务中表现是否稳定，用统计中的变异系数（ $cv = \sigma/\mu$ ，即标准差除以均值）衡量：每次得分差不多就满分，忽高忽低就低分。
- **行为一致性量化：**统计 Agent 使用了哪些工具、各用了多少次，用 Shannon 信息熵公式 $C = 1 - H(X)/H_{\max}$ （其中 $H(X) = -\sum p(x_i) \log_2 p(x_i)$ ）计算一致性分数。 C 接近 1 说明行为很聚焦（总是用同一种工具），接近 0 说明很分散。这把”人格是否影响行为”变成了可以算出来的数学问题。
- **诊断证据链：**每个维度的分数都有具体证据支撑，比如”思考次数偏少（5 次），内部推理不充分”或”回复长度标准差：42，能根据情境调整表达方式”。配合决策风格分类（分析型/直觉型/果断型/谨慎型）和劣化趋势检测（对比最近 3 次与前 3

次评测)，评测结果不是一个黑箱数字，而是可以看到”为什么这个维度得了这个分”的完整证据链。

成果：不同 Agent 的行为模式可以在同一尺度上比较，评测结果完全可解释。4 次完整 Bench 评测（3 Agent × 3 场景 × 3 重复 = 27 条/次）积累了 94 条评测子结果，鲁棒性平均 92.8 分（跨场景高度稳定），人格一致性揭示了后续优化方向（平均 32.9 分）。

6 大模型应用深度与调试优化

Life Lab 通过 OpenAI 兼容 API 统一接入多种大语言模型，评测中使用 DeepSeek-V4-Flash（api.deepseek.com），同时支持 GLM、OpenAI 等模型的无缝切换。

6.1 模型接入与调用方式

- **双模式调用：**系统为不同场景配置了”思考”（think）和”行动”（act）两种 LLM 配置，思考模式使用较高温度用于深度推理（如人格铸造、关系评估），行动模式使用较低温度用于快速决策（如工具调用、动作选择）。
- **Prompt 工程：**采用”冻结核心 + 动态上下文”双层 System Message 结构，核心层（身份、价值观、目标）初始化后不变，上下文层（处境、记忆、笔记）每 tick 注入，确保人格一致性与环境感知的平衡。
- **联网搜索：**集成 DeepSeek Responses API 内置联网搜索，并配备搜狗/百度/Bing 多引擎并行兜底，支持断路器保护避免连续失败。

以 Worker 决策 Prompt 为例，展示系统的结构化 Prompt 设计：系统向 LLM 发送的决策请求包含当前任务描述、已制定的执行计划、已完成步骤摘要、当前工作区文件列表、上一步操作及结果、可用工具列表。LLM 必须返回严格 JSON 格式，包含 decision（tool_call / deliverable / done）、tool_name、tool_args、reason 四个字段。这种结构化输出设计避免了自由文本解析的不可控性——系统从不在 Prompt 中暴露 JSON Schema 语法（模型容易混淆 ”a” | ”b” 这类写法），而是通过具体示例引导格式。

6.2 容错与调试策略

针对 LLM 系统的固有不稳定性，平台实现了多层次的容错与调试机制：

- **超时重试与指数退避**: 所有 LLM 调用包装在统一的异步调用器中, 重试间隔采用指数退避 (2s、4s、8s), 避免对 API 服务造成压力。
- **断路器保护**: 联网搜索模块实现断路器机制, 连续失败达到阈值后自动断开, 避免反复超时拖慢系统。
- **统一错误分类**: 通过 LLMErrorClassifier 将上游 OpenAI 兼容异常 (AuthenticationError、RateLimitError、TimeoutError、ConnectionError) 转换为用户友好的中文提示, 方便定位问题。
- **LLM 不可用降级**: 任务分解、关系评估等关键路径均有规则兜底方案, LLM 不可用时自动降级为基于关键词/角色的规则引擎, 确保系统在任何环境下可用。
- **评测趋势监控**: BenchLab 自动检测评测分数连续下降趋势 (对比最近 3 次评测), 及时提醒用户可能存在的模型退化问题。
- **JSON 解析重试实战**: 在实际运行中, Agent 在反思阶段 (REFLECTING) 反复输出非 JSON 内容 (如”好的, 让我继续执行”), 导致解析失败。调试发现原因是 Prompt 中的示例过于简短, 模型在长上下文中容易”忘记”格式要求。解决方案: 在 JSON 解析失败时, 系统自动追加格式提示 (包含完整示例), 并在最多 3 次重试后强制将 Agent 推进到下一步, 避免死循环。这一机制使 Worker 的 JSON 解析成功率从约 85% 提升到 98% 以上。

7 评测数据与实证分析

平台在实际运行中积累了完整的评测数据, 所有数据存储于 SQLite 数据库, 以下数据均从数据库中直接提取。

7.1 评测数据总览

数据类型	记录数
Bench 完整评测运行	4 次（全部完成，27/27 任务）
Bench 子结果	94 条
Arena 竞技对抗	1 场（6 人大乱斗）
Team 团队协作	5 个团队，14 个计划
Agent 实例	25 个
World 世界实例	48 个
Simulation 模拟运行	47 次

4 次 Bench 评测均使用 deepseek-v4-flash 模型，采用标准评测套件（3 Agent × 3 场景 × 3 重复 = 27 条评测记录/次）。

7.2 六维雷达评测结果

维度	运行 1	运行 2	运行 3	运行 4	平均
人格一致性	32.6	31.2	35.1	32.6	32.9
决策质量	32.8	33.8	37.4	35.6	34.9
交互深度	32.6	34.3	35.7	33.7	34.1
鲁棒性	92.6	92.4	92.0	94.1	92.8
创造力	57.8	57.2	54.1	57.4	56.6
适应性	89.3	87.0	86.6	92.3	88.8

鲁棒性使用变异系数计算： $cv = \sigma/\mu$ ， $R = \max(0, 100 - cv \times 100)$ 。

7.3 分 Agent 与分场景聚合

Agent	场景	人格	决策	交互	鲁棒	创造	适应
学霸小明	期末周	45.8	30.0	28.4	80.0	66.0	91.7
学霸小明	新生报到	33.1	30.0	26.8	80.0	58.8	97.7
社交小红	毕业选择	38.2	33.1	30.2	80.0	57.5	81.1
领导者小刚	毕业选择	30.0	55.0	66.4	80.0	49.3	100.0
领导者小刚	新生报到	30.0	33.6	40.1	80.0	53.1	78.4

7.4 评测结果分析

- **鲁棒性最强**（平均 92.8 分）：模型在跨场景、跨重复运行中表现高度稳定。
- **人格一致性最弱**（平均 32.9 分）：Agent 行为未能严格遵循 MBTI 设定，是后续优化的核心方向。
- **人格与场景耦合**：学霸小明在期末周人格一致性最高（45.8），领导者小刚在毕业选择场景交互深度最高（66.4）。
- **适应性波动显著**（78.4-97.7）：不同人格对环境变化的响应模式存在显著差异。

8 应用场景与推广价值

Life Lab 的独特能力——人格驱动行为、可信赖协作、可解释评测——使其不仅是一个技术平台，更是一个能真正帮助学生成长的工具。

8.1 个性化成长指导

一个迷茫的大二学生面对”要不要转专业”的抉择：打开 Life Lab，创建一个”理性务实的 ESTJ 学长”和一个”感性包容的 ENFP 学姐”，分别向它们倾诉困惑。ESTJ 学长会直接列出转专业的利弊清单、就业率数据，给出果断建议；ENFP 学姐会先共情她的焦虑，分享自己探索兴趣的经历，引导她自己想清楚。两个 Agent 的建议风格完全不同，但都基于各自的人格参数，真正拥有不同决策风格（分析型 vs 直觉型）的 AI 角色。学生可以在 Life Lab 中同时咨询多个不同人格的 Agent，获得多元化的视角，最终自己做出判断。

8.2 AI 同伴社交模拟

当多个具有不同性格的 Agent 被放入同一校园场景，会自然涌现出小团体、意见领袖、冲突与和解：这帮助学生直观理解“不同性格的人如何相处”。学生可以观察：内向的 Agent 如何在小范围内建立深度关系，外向的 Agent 如何成为社交中心，不同决策风格的 Agent 面对同一事件如何做出截然不同的选择。这种可重复、可量化的社会模拟，为心理学和人际交往提供了全新的实验视角。

8.3 可信赖的多 Agent 协作

学生还可以让多个 Agent 组队完成复杂任务——如“策划校园科技节”：一个 Agent 负责调研往届案例，一个负责设计活动方案，一个负责撰写预算报告。所有交付由程序直接验证（算式直接算一遍、工具记录直接查一遍），不存在“Agent 声称做了但实际没做”的幻觉。首次不通过时自动退回修订，最多两轮，确保每一步都真正执行。

8.4 AI 人格实验与教学

Life Lab 提供了从“铸造人格 → 投放场景 → 观察行为 → 量化评测 → 调整优化”的完整闭环，使抽象的 AI 概念（人格建模、行为涌现、多智能体协作）变得可感知、可实验。不同大语言模型（DeepSeek、GLM、GPT 等）在相同人格设定下的行为差异，也可以通过六维雷达和行为一致性分数进行量化比较——传统基准测试只能衡量“答题能力”，Life Lab 揭示的是“行为风格”。

9 总结

大多数 Agent 项目止步于“让 Agent 完成任务”。Life Lab 关注的是一个旁路但重要的问题：当 Agent 拥有了性格、情绪和同伴，它们会怎样？

七个阶段、12 个模块的持续迭代，Life Lab 构建了三项其他框架不具备的能力：**人格直接决定行为**（MBTI 贯穿对话/移动/情绪全链路）、**程序直接验证交付**（DAG 管道编排 + AST 硬校验 + 自动修订闭环）、**基于信息论和统计学的量化评测**（六维雷达 + 信息熵指纹 + 变异系数鲁棒性）。这三项能力使 Life Lab 从“有趣的 Agent 玩具”跃升为“可量化、可编排、可涌现的 Agent 社会实验平台”。

平台在实际运行中积累了 94 条评测子结果，鲁棒性维度平均得分 92.8 分（跨场景高度稳定），为模型行为分析提供了可量化的实验基础。系统支持 DeepSeek / GLM /

OpenAI 多种大模型，通过 OpenAI 兼容 API 统一接入，内置超时重试、断路器与降级兜底，确保在任何环境下可用。

Life Lab 不只是一个竞赛作品，它是一个研究者和学生可以真正用来探索 AI 社会性行为的工具。人格可以被铸造，行为可以被观测，涌现可以被量化，协作可以被信赖。这是 Life Lab 与其他 Agent 项目最本质的区别。