



Life Lab: AI Agent 社会实验平台

设计文档

赵俊宇 刘福康 岳雨婷

(中国科学技术大学 信息科学技术学院)

摘 要

本文档描述AI Agent 社会实验平台 Life Lab 的系统设计。平台采取**“快慢结合”**、多链路并行的设计思想：关键词匹配能快速给出初步判断，但不够准确；LLM 深度评估需要数秒，但更可靠。两条独立路径互相保险，对抗 LLM 可能产生的错误。在此哲学之上，平台实现了三项核心能力：**人格驱动的社会涌现**（MBTI 人格直接决定 Agent 怎么移动、怎么社交、怎么产生情绪）、**可信赖的多 Agent 协作**（程序直接验证每一步是否真正执行）和**可解释的行为评测**（六个维度打分 + 信息论量化行为一致性 + 逐维度诊断证据链）。本文档重点阐述 M9-M12 四个进阶模块的设计决策，揭示从基础模块到进阶能力的生长脉络。

核心亮点

- “多链路设计”：关键词匹配 1ms 出结果，LLM 深度评估数秒但更可靠，双路径互保
- 人格直接决定行为：MBTI 等可直接驱动对话/移动/情绪三维度，从“说什么”到“怎么走”全链路一致
- 程序直接验证交付：算式直接算一遍、工具记录直接查一遍，不依赖 LLM 判断
- 用信息论量化行为 + 跨任务鲁棒性 + 逐维度诊断，确保行为评测从定性走向定量
- 20 页面 + Phaser 3 + 图形化管线编辑器，保障系统完整度与工程成熟度

关键词：AI Agent；系统架构；人格建模；多智能体协作；行为指纹；管道编排

目录

1	引言	5
1.1	设计目标	5
1.2	设计原则	5
1.3	竞品对比与设计定位	5
2	系统总体架构	6
3	基础模块设计（M1–M8）	6
3.1	人格数据模型（M1）	6
3.2	世界引擎与关系双轨评估（M2/M3）	7
3.3	叙事、竞技与干预（M4–M8）	7
4	团队协作引擎（M9）	8
4.1	设计决策一：文件系统与消息通信	8
4.2	设计决策二：LLM 分解 + 规则兜底	8
4.3	设计决策三：团队诊断与容错	8
5	评测基准（M10）	8
5.1	设计决策一：鲁棒性为什么是跨任务指标	9
5.2	设计决策二：行为指纹为什么用信息熵	9
5.3	设计决策二-b：决策风格如何量化分类	10
5.4	设计决策三：诊断评分的设计动机	10
6	游戏化场景（M11）	10
6.1	设计决策一：MBTI 到行为的映射	11
6.2	设计决策二：情绪引擎的多重触发	11
6.3	设计决策三：目标预订防碰撞协议	12
7	管道编排引擎（M12）	12
7.1	设计决策一：Loop/Branch的设计动机	12
7.2	设计决策二：确定性硬校验的设计动机	13
7.3	设计决策三：自动修订机制	13

8	平台运行评测数据	13
8.1	评测数据总览	14
8.2	六维雷达评测结果	14
8.3	分 Agent 与分场景聚合	14
8.4	Arena 竞技对抗记录	15
8.5	团队协作运行统计	15
8.6	评测结果分析	15
9	技术亮点总结	16
10	前端交互层	16
11	数据库设计	18
12	总结	18

1 引言

1.1 设计目标

1. 人格真实性: Agent 行为应与其人格参数保持一致, 不同人格在相同场景下表现出可辨识的行为差异。
2. 可扩展性: 引擎层通过 Mixin 模式组合能力, 新功能添加不影响既有系统。
3. 实时性: 通过 SSE 实现毫秒级事件推送, 前端实时渲染 Agent 思维流和行为。
4. 鲁棒性: LLM 调用具备超时、重试和降级机制, 关键路径均有规则兜底方案。

1.2 设计原则

- 引擎与 API 分离: 核心逻辑封装在引擎层 (engines), API 层仅负责路由和参数校验。
- LLM 优先 + 规则兜底: 关键决策优先使用 LLM, 不可用时降级为规则引擎。
- 多链路设计: 关键词匹配能在 1ms 内给出初步判断 (每 tick, $O(n)$), 但不够准确; LLM 深度评估需要数秒, 但更可靠。两条路径独立运行、互为保险, 快的保证实时性, 慢的保证准确性。形式化地, 最终判定为 $D = D_{fast} \oplus D_{slow}$, 任一路径异常即触发告警。这一模式在关系评估、任务分解、交付验收等多个模块中反复出现, 是平台的核心工程哲学。

1.3 竞品对比与设计定位

	人格建模	行为评测	游戏化场景	交付验证
AutoGen / CrewAI	✓ (基础)	—	—	—
LangGraph	—	—	✓ (静态可视化)	—
AgentBench	—	✓ (黑箱评分)	—	—
Life Lab	✓	✓ (可解释)	✓ (实时交互)	✓

现有 Agent 框架各有侧重, 但均缺乏”人格-行为-评测”的完整链路。Life Lab 的独特定位是: 不仅是 Agent 编排工具, 更是 Agent 社会实验平台。

2 系统总体架构

系统采用四层架构：

- 1. 表现层：React + TypeScript + TailwindCSS + Phaser 3，通过 React Query 管理服务端状态，SSE 接收实时事件。
- 2. 接口层：FastAPI 路由层，提供 RESTful API 和 SSE 端点。
- 3. 引擎层：persona/、agent_factory/、world/、narrative/、arena/、team/、bench/、worker/ 八大引擎。
- 4. 数据层：Pydantic 模型 + SQLAlchemy 异步 ORM + SQLite/aiosqlite。

3 基础模块设计（M1–M8）

基础模块覆盖 Agent 从”诞生”到”沉淀”的完整生命周期，为进阶能力提供不可或缺的人格基底和行为数据。

3.1 人格数据模型（M1）

组件	类型	说明
MBTI	string	16 种人格类型 + T/A 变体
BigFive	struct	五维浮点参数 (0–1)：开放性、尽责性、外向性、宜人性、神经质
DecisionStyle	struct	四维决策风格：信息处理、风险偏好、社交倾向、压力应对
Values	list[string]	核心价值观列表
Narrative	string	200–400 字人格画像
Background	struct	背景故事（家乡、家庭、教育、关键事件）
Goals	list[Goal]	层级化目标（优先级 + 截止日期 + 进度）
EmotionalState	struct	VAD 三维情绪模型（愉悦度、唤醒度、支配感）

PersonaBuilder 接收自然语言描述，通过 LLM 生成完整人格 JSON。System Message 采用”冻结核心 + 动态上下文”双层结构：核心层（身份、价值观、目标）初始化后不变，上下文层（处境、记忆、笔记）每 tick 注入，确保人格一致性与环境感知的平衡。

3.2 世界引擎与关系双轨评估 (M2/M3)

世界引擎采用离散时间模拟 (Tick-Based)，每个 tick 顺序执行：构建上下文、注入 Agent、执行决策、后处理 (Tool 副作用、目标更新、关系演化)、推送 SSE 事件。

Agent 之间的关系不是简单的“好友/敌人”二分，而是一个 $[-1, +1]$ 的连续分数。分数的更新采用两条路径协同工作：

- **快速路径** (每 tick)：检测对话中的关键词 (如“谢谢”“讨厌”“一起”)，匹配 7 种交互类型，即时更新关系分数。1ms 内完成，保证每 tick 都有反馈。
- **深度路径** (每 3 tick，异步)：让 LLM 阅读全部事件，评估关系变化。能捕捉关键词无法识别的微妙情感 (如反讽、暗示)，但需要数秒。

快速路径保证实时性，深度路径补充准确性，两者协同使关系演化既实时又准确。

7 种交互类型及其对关系分数的影响：

类型	Δ	典型关键词
友好 (friendly)	+0.10	谢谢、喜欢、欣赏、支持
敌对 (hostile)	-0.15	讨厌、滚、闭嘴、嘲讽
合作 (cooperative)	+0.08	一起、合作、讨论、分享
竞争 (competitive)	-0.05	比、赢、挑战、超过
支持 (supportive)	+0.12	我相信你、别担心、有我在
轻视 (dismissive)	-0.10	随便、无所谓、别烦我
好奇 (curious)	+0.05	为什么、你怎么看、然后呢

关系分数在 $[-1, +1]$ 区间内累积演化， $A \rightarrow B$ 和 $B \rightarrow A$ 独立计算，确保同一对 Agent 可以存在不对称关系。快速路径保证每 tick 都有关系更新，深度路径补充微妙的情感信号，两者协同使关系演化既实时又准确。

3.3 叙事、竞技与干预 (M4-M8)

叙事引擎 (M5) 将 Agent 经历转化为 9 种文体叙事 (小说/日记/信件/播客等)，保持 Agent 口吻一致。**竞技引擎** (M4) 支持辩论、面试、路演、盲测和大乱斗五种模式，裁判从四维度评分。**控制台** (M6) 提供上帝视角仪表盘和决策模式识别。**干预台** (M7) 支持运行时注入事件和私密指令。**档案馆** (M8) 实现实验回放、模板沉淀和报告导出。

4 团队协作引擎 (M9)

M9 实现完整的多 Agent 协作 workflow。以下聚焦三个核心设计决策。

4.1 设计决策一：文件系统与消息通信

方案：Agent 间通过共享文件系统协作，而非消息队列或 API 调用。

理由：文件系统天然具备可追溯性（所有协作留痕）、可调试性（随时查看任意步骤的输入输出）和可回放性（实验可完整复现）。每步工作区自动复制上游成功步骤的产出文件给下游，确保信息传递不依赖 Agent 的“记忆”。

隔离规则：Team 工作区与 Worker 工作区位于不同父目录，互不干扰。Team 工作区包含共享任务描述 (TASK.md)、团队配置 (TEAM.json) 和每步骤的上下文文件。

4.2 设计决策二：LLM 分解 + 规则兜底

方案：任务分解优先使用 LLM，LLM 不可用时降级为基于角色的规则分配（8 种预设角色模板）。

理由：LLM 分解灵活但不可靠（可能返回不存在的 Agent 名字），规则分解可靠但死板。两者结合既保证了正常路径的智能性，又保证了降级路径的可用性。安全网机制自动将 LLM 返回的名字映射为合法 UUID。

角色演化：每个步骤成功后，LLM 作为“团队观察者”评估 Agent 实际表现并动态调整其角色描述，使团队分工在执行中自我优化。

4.3 设计决策三：团队诊断与容错

团队诊断：DiagnosticsEngine 实时监控参与度（静默过久触发告警）、参与度评分（基于发言占比）和冲突检测（同一 tick 内过多并行操作时标记）。

容错机制：步骤失败时，保留已完成上下文，仅对剩余步骤重新分解，避免从零开始。Worker 内部具备 JSON 解析重试和 LLM 调用指数退避机制。

5 评测基准 (M10)

M10 的设计核心是可解释的行为分析，即：不仅给分，还要解释“为什么”。

5.1 设计决策一：鲁棒性为什么是跨任务指标

问题：单次任务中的”鲁棒性”无法衡量、LLM存在随机性，一个 Agent 在一次模拟中可能碰巧表现很好。

方案：单任务中的鲁棒性只是占位值。通过一个 Agent 在多次任务中得分是否稳定评估。用统计中的**变异系数**（Coefficient of Variation）来衡量。设 n 次评测的分数为 $s_1, s_2, \dots, s_n$ ，定义：

$$\mu = \frac{1}{n} \sum_{i=1}^n s_i, \quad \sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (s_i - \mu)^2}, \quad cv = \frac{\sigma}{\mu}$$

则鲁棒性指标为：

$$R = \max(0, 100 - cv \times 100)$$

当所有任务分数完全一致时 $cv = 0$ ， $R = 100$ （满分）；分数波动越大， cv 越大， R 越低。

设计考量：失败任务的零分也进入聚合，避免只统计成功样本导致结果虚高。例如，某 Agent 在 3 次评测中得分为 80、82、78，则 $\mu = 80$ ， $\sigma \approx 1.63$ ， $cv \approx 0.02$ ， $R \approx 98$ ，则表现极其稳定。

5.2 设计决策二：行为指纹为什么用信息熵

问题：如何量化”Agent 的行为是否一致”？简单的统计量（如平均值）无法捕捉行为分布的特征。

方案：思路很直接：统计 Agent 使用了哪些工具、各用了多少次。如果总是用同一种工具，说明行为很聚焦；如果均匀地使用各种工具，说明行为很分散。用 Shannon 信息熵（Shannon, 1948）把这个直觉变成公式。设 Agent 在 T 个 tick 内共调用 N 次工具，各工具调用频率为 $n_1, n_2, \dots, n_k$ （ $\sum n_i = N$ ），定义概率分布 $p(x_i) = n_i/N$ ：

$$H(X) = - \sum_{i=1}^k p(x_i) \log_2 p(x_i)$$

最大熵 $H_{\max} = \log_2 k$ （均匀分布时取到）。定义**行为一致性分数**：

$$C = 1 - \frac{H(X)}{H_{\max}}$$

$C \in [0, 1]$ ： $C \rightarrow 1$ 表示行为高度聚焦（几乎只用一种工具）， $C \rightarrow 0$ 表示行为高度分散（均匀使用所有工具）。

具体示例: Agent A 在 10 次调用中全部使用同一工具 (observe), 则 $H = 0$, $C = 1.0$, 行为高度聚焦, 为”观察型”Agent。Agent B 均匀调用 3 种工具各 3-4 次, 则 $H \approx 1.585 = H_{\max}$, $C \approx 0.0$, 行为高度分散, 为”多面手”Agent。信息熵有效区分了两种截然不同的行为模式。

5.3 设计决策二-b: 决策风格如何量化分类

问题: 一致性分数 C 只能衡量行为的聚焦/分散程度, 无法区分”聚焦于什么”。

方案: 从 Agent 的动作关键词中提取四类决策风格并量化占比。设 Agent 的动作关键词集合为 A , 四类关键词集分别为:

- 分析型 K_α : 分析、判断、计划
- 直觉型 K_β : 想要、尝试、选择
- 果断型 K_γ : 决定、坚持、接受
- 谨慎型 K_δ : 避免、拒绝、妥协

各风格占比定义为 $\alpha = |\{a \in A : a \in K_\alpha\}|/|A|$, β 、 γ 、 δ 同理。当某一类占比 $> 30\%$ 时归为对应风格 (可叠加, 如”分析型+果断型”), 否则为”平衡型”。配合逐维度诊断证据链 (思考次数、消息长度、回复标准差等), 评测结果完全可解释。

5.4 设计决策三: 诊断评分的设计动机

问题: 传统评测只给分数。用户无法判断这个分数是否合理。

方案: 诊断评分从原始事件证据中逐维度追溯评分原因。例如”思考次数偏少(5次), 内部推理不充分”或”回复长度标准差: 42, 能根据情境调整表达方式”。配合劣化趋势检测 (对比最近 3 次与前 3 次评测), 可以看到完整的证据链。

6 游戏化场景 (M11)

M11 的核心创新是 MBTI 人格到游戏行为的端到端映射, 通过构建随机引擎, 实现人格不仅影响”说什么”, 还影响”怎么走”和”如何感受”。

6.1 设计决策一：MBTI 到行为的映射

选择：MBTI 直接推导移动参数（间隔、范围、空闲率），而非通过 prompt 间接影响。

映射规则：E/I 维度决定活动频率（外向型移动间隔短），T/F 维度决定行为倾向，N/S 维度决定探索范围。4 种人格组合各有独立的移动配置。

混合策略：移动目标选择采用物品寻求 + 社交接近 + 随机漫游的混合策略，使 Agent 的行为既有目的性又有随机性。

6.2 设计决策二：情绪引擎的多重触发

选择：EmotionEngine 集成五重触发链，而非单一的情绪模型。

- **对话触发：**关键词规则匹配 8 种情绪，对话气泡弹出时即时分析。
- **环境触发：**场景氛围（6 种场景各有情绪偏向）+ 邻近物品情绪影响。
- **社交共鸣：**近距离同情绪 Agent 互相放大，异情绪互相中和。
- **随机事件：**场景事件池（6 种场景共 25+ 事件）定期触发。
- **衰减回归：**情绪强度自然向中性回归。

理由：单一触发（如只有对话触发）不够真实。真实的情绪受多种因素共同影响，例如对话内容、所处环境、社交对象、突发事件和自然消退。五重触发链使 Agent 的情绪变化更加自然和可观察。

场景氛围与物品情绪的具体设计：

场景	氛围情绪	物品	情绪影响
图书馆	中性	床/沙发	疲倦
宿舍	疲倦	钢琴/喷泉	愉悦
教室	焦虑	自动售货机	兴奋
艺术中心	愉悦	电脑	困惑
实验室	困惑	地球仪	惊讶
樱花大道	愉悦(×2)	树/盆栽	愉悦/中性

系统还维护了 25+ 条场景随机事件（如“图书馆突然停电”“实验数据突然对上了”“花瓣纷纷飘落”等），每 30–70s 随机触发一条，影响全体或随机个体。情绪引擎通过三条独立定时器协同工作：衰减定时器（每 30s 情绪向中性回归一级）、环境定时器（每 30s 场景与物品情绪微调）、随机事件定时器（30–70s 间隔），使 Agent 的情绪变化具有真实的时间节律。

6.3 设计决策三：目标预订防碰撞协议

选择：借鉴分布式系统的资源预订协议（Reserve-Move-Release 三步），而非简单的碰撞检测。

理由：碰撞检测是“事后补救”（碰撞发生后再处理），目标预订是“事前预防”（移动前先确认目标格可用）。这确保了即使在高并发场景下，Agent 的空间行为也是确定性的，保障同一格不会被分配给两个 Agent。

7 管道编排引擎（M12）

M12 的核心是一个支持复杂控制流的 DAG 管道编排引擎。

Worker 是管道中的执行单元，每个 Worker 通过显式状态机管理任务生命周期，共 6 个正常状态：IDLE（等待任务）→ PLANNING（制定执行计划）→ DECIDING（决策下一步）→ EXECUTING（执行工具调用）→ REFLECTING（反思结果）→ DONE（完成）。反思阶段可回到 DECIDING（继续）、PLANNING（修订计划）或直接到 DONE。系统设有最大步数限制防止无限循环。错误处理采用三级策略：RETRYABLE（网络超时等，自动重试）、SKIPPABLE（文件缺失等，Agent 自主决策）、FATAL（API 连续失败等，立即终止）。特别地，REFLECTING → PLANNING 的“修订”路径使 Worker 能根据交付验收反馈自动调整计划并重新执行，形成“执行→验收→修订”的闭环迭代。

7.1 设计决策一：Loop/Branch 的设计动机

问题：简单 DAG 只能表达“一次性”执行。现实中很多 workflows 需要迭代（“分析 → 评审 → 不合格则修改”）和条件跳转（“如果搜索到足够信息则跳过补充搜索”）。

方案：在标准 DAG 的 FLOW 边之外，增加 LOOP（回边循环）和 BRANCH（条件跳转）两种边类型。条件值从节点真实产出文件中读取，支持正则匹配、数值比较和关键词检测三种模式。

执行策略：拓扑排序后按层级执行，同层节点最多 3 路并行。Loop 触发时将回边路径上的节点重新入队，Branch 触发时 BFS 标记被绕过节点为跳过。

7.2 设计决策二：确定性硬校验的设计动机

问题：LLM 验收员本身也可能产生“幻觉”，它可能误判一个有算式错误的交付为“通过”。这是 LLM 系统的固有风险。

方案：在 LLM 验收之前，先让程序自己检查，而不是让 LLM 去“看”算式对不对（可能看错），不如直接让程序算一遍。具体有两道检查：

1. **算式 AST 求值：**对交付物中的数学表达式，解析为抽象语法树（AST）后直接求值，判断计算是否正确。例如 “ $3 + 5 \times 2$ ” 解析为 `Add(3, Mul(5, 2))`，求值得 13，与交付结果比对。
2. **工具台账核验：**检查 Agent 声称执行的工具调用是否在机器台账中有真实记录，查验工具名是否存在、参数是否合法、返回值是否已写入产出文件。

硬校验发现的问题强制标记为失败，即使 LLM 验收员误判也无法绕过。

设计考量：确定性规则（快速硬校验， $O(1)$ 判断）与 LLM 判断（慢速语义评估）互相保险。其核心洞察是：用确定性对抗随机性，规则校验不会“幻觉”，而 LLM 判断可能“幻觉”，两条独立路径防止同源错误。

7.3 设计决策三：自动修订机制

选择：首次验收不通过时，将问题反馈送回 Worker 自动修订，最多两轮复验。

理由：验收不视作终点，而是迭代的一部分。自动修订使 Agent 有机会纠正错误，而不是简单地标记失败。超过修订上限后，当前工作区保留，用户可手动补充。

8 平台运行评测数据

平台在实际运行中积累了完整的评测数据，所有数据存储于 SQLite 数据库（`lifelab.db`），以下数据均从数据库中直接提取。

8.1 评测数据总览

数据类型	记录数
Bench 完整评测运行	4 次（全部完成，27/27 任务）
Bench 子结果	94 条
Arena 竞技对抗	1 场（6 人大乱斗）
Team 团队协作	5 个团队，14 个计划
Agent 实例	25 个
World 世界实例	48 个
Simulation 模拟运行	47 次

4 次 Bench 评测均使用 deepseek-v4-flash 模型，采用标准评测套件（3 Agent × 3 场景 × 3 重复 = 27 条评测记录/次）。标准 Agent 为学霸小明（INTJ-T）、社交小红（ENFP-A）、领导者小刚（ESTJ-A），标准场景为期末周、新生报到、毕业选择。

8.2 六维雷达评测结果

每次评测从人格一致性、决策质量、交互深度、鲁棒性、创造力、适应性六个维度（每维 0–100 分）对 Agent 行为进行量化评分。4 次运行的评分如下：

维度	运行 1	运行 2	运行 3	运行 4	平均
人格一致性	32.6	31.2	35.1	32.6	32.9
决策质量	32.8	33.8	37.4	35.6	34.9
交互深度	32.6	34.3	35.7	33.7	34.1
鲁棒性	92.6	92.4	92.0	94.1	92.8
创造力	57.8	57.2	54.1	57.4	56.6
适应性	89.3	87.0	86.6	92.3	88.8

其中鲁棒性使用变异系数计算： $cv = \sigma/\mu$ ， $R = \max(0, 100 - cv \times 100)$ ，即 Agent 在多次重复评测中得分越稳定，鲁棒性越高。

8.3 分 Agent 与分场景聚合

下表展示各 Agent 在不同场景下的平均评分（跨 4 次运行聚合）：

Agent	场景	人格	决策	交互	鲁棒	创造	适应
学霸小明	期末周	45.8	30.0	28.4	80.0	66.0	91.7
学霸小明	新生报到	33.1	30.0	26.8	80.0	58.8	97.7
学霸小明	毕业选择	31.0	34.2	34.5	80.0	55.1	88.6
社交小红	毕业选择	38.2	33.1	30.2	80.0	57.5	81.1
社交小红	期末周	30.0	36.2	36.1	80.0	52.0	85.8
社交小红	新生报到	30.0	33.1	22.2	80.0	53.5	90.8
领导者小刚	毕业选择	30.0	55.0	66.4	80.0	49.3	100.0
领导者小刚	期末周	30.0	30.3	32.7	80.0	57.0	86.0
领导者小刚	新生报到	30.0	33.6	40.1	80.0	53.1	78.4

8.4 Arena 竞技对抗记录

平台记录了 1 场 6 人 Arena 大乱斗（创业路演主题：有限校园创新基金应该交给谁使用），采用逐阶段淘汰制，LLM 裁判从逻辑性、创造性、表达力、人格一致性四维度评分。最终林启明获得冠军，慧兰获得亚军。比赛经历 3 个阶段、42 轮发言，完整记录了每位参赛者的思维链（think_aloud）和对话内容。

8.5 团队协作运行统计

5 个团队共执行 14 个计划，验证了以下核心特性：

- 任务分解：LLM 分解失败时自动降级为规则分配
- 执行幂等性：重复执行不会创建重复记录
- 交付硬校验：算式 AST 求值 + 工具台账核验（程序直接验证，不依赖 LLM）

8.6 评测结果分析

1. 鲁棒性最强（平均 92.8 分）：模型在跨场景、跨重复运行中表现高度稳定，输出一致性好。
2. 人格一致性最弱（平均 32.9 分）：Agent 行为未能严格遵循 MBTI 设定，人格参数对行为的约束力不足，是后续优化的核心方向。

3. **不同 Agent 在不同场景下表现差异明显**：学霸小明在期末周（高压学术场景）人格一致性最高（45.8），领导者小刚在毕业选择场景交互深度最高（66.4），体现了人格与场景的耦合效应。
4. **适应性维度波动较大（78.4–97.7）**：学霸小明在新生报到场景适应性最强（97.7），领导者小刚在新生报到场景最弱（78.4），说明不同人格对环境变化的响应模式存在显著差异。

9 技术亮点总结

1. **人格直接决定行为**：MBTI 不仅影响 Agent 的对话风格，还直接决定移动频率、社交倾向和情绪变化，从“说什么”到“怎么走”再到“如何感受”，人格参数贯穿了 Agent 的全部行为维度。
2. **“快慢结合”双路径互保**：关键词匹配能在 1ms 内给出初步判断，但不够准确；LLM 深度评估需要数秒，但更可靠。在交付验收中，程序直接算一遍算式对不对、查一遍工具调用记录是否真实存在，不依赖 LLM 判断。这一模式在关系评估、任务分解、交付验收中反复出现。
3. **用信息熵量化行为**：统计 Agent 的工具使用习惯，用信息熵公式计算行为一致性分数，将“人格是否影响行为”从主观判断变为可计算的数学命题。配合逐维度诊断证据链和决策风格分类，评测结果完全可解释。
4. **数据驱动的评测体系**：4 次完整 Bench 评测（94 条子结果）积累了大量实际运行数据，鲁棒性维度平均 92.8 分（跨场景高度稳定），人格一致性维度揭示了后续优化方向（平均 32.9 分），为模型行为分析提供了可量化的实验基础。

10 前端交互层

前端采用 React 18 + TypeScript + Vite，核心技术选型：

- **UI**：TailwindCSS + Lucide Icons
- **状态管理**：React Query（服务端状态）+ Zustand（客户端状态）
- **实时通信**：useSSE hook 封装 EventSource，支持自动重连和事件类型分发

- 游戏渲染: Phaser 3 集成 M11 游戏化场景
- 图表: Recharts 绘制雷达图、折线图等

前端包含 **20** 个主要页面，按功能分组：

模块	页面	功能描述
通用	Home, GuidePage, Settings	首页、功能引导、设置
M1	AgentFoundry, AgentModule	人格铸造、Agent 管理
M2/M3	SoloTheater, GroupSandbox, GameScene	单人/群体场景、游戏渲染
M4	Arena, DuelArena	竞技场、对决
M5	NarrativeFactory	叙事生成
M6/M7	ControlPanel, DirectorIntervention	控制台、干预
M8	Archive, ShowcaseWall	档案、展示
M9	TeamDashboard	团队监控
M10	BenchLab	评测实验
M12	WorkerBench, PipelinePage, PipelineEditor	Worker、管线管理、图形化编辑器

其中 PipelineEditor 提供基于 React Flow 的图形化管线编辑器，支持拖拽创建节点、连线定义依赖、实时运行监控。GameScene 集成 Phaser 3 渲染 M11 游戏化场景，Agent 在瓦片地图上自主移动、社交和情绪表达。

11 数据库设计

表名	说明
AgentRow	Agent 持久化（人格 JSON、情绪状态、指纹 JSON）
WorldRow	世界配置（场景、Agent 列表、Tick 数）
TeamRow	团队配置（成员、状态）
PlanRow	团队执行计划（任务、步骤、进度、结果）
BenchRun	评测运行（配置、状态、得分）
BenchResult	单条评测结果（指标、事件 JSON）
MemoryRow	Agent 长期记忆

数据库访问通过 `async_session()` 管理，使用 `aiosqlite` 驱动实现全异步操作。

12 总结

Life Lab 通过七大阶段的持续迭代，构建了一个功能完备且具有技术深度的 AI Agent 社会实验平台。系统的核心竞争力在于：

1. **完整性**：12 大模块覆盖 Agent 全生命周期，从人格铸造到行为评测到实验沉淀。
2. **深度**：用信息论量化行为一致性、用程序级校验解决交付可信度、Loop/Branch 管道支持迭代控制流，为解决 Agent 系统中的真实痛点提供可能的方案。
3. **一致性**：人格参数从对话到游戏行为的全链路映射，“人格驱动行为”不是口号，而是可验证的工程事实。
4. **工程成熟度**：关键词检测保证实时性，LLM 深度评估保证准确性，程序级校验防止 LLM 判断出错。

未来工作方向：更精细的人格-行为映射模型（超越 MBTI 粗粒度分类，引入大五人格连续谱）、3D 场景支持（Three.js/WebGPU 沉浸式观察）、更大规模社会模拟（50+

Agent 复杂社会结构涌现)、以及基于强化学习的 Agent 行为优化。最终目标是构建一个真正的“AI 社会实验室”——让研究者能够以前所未有的深度和规模,探索 AI Agent 的社会性行为。